

Universidade do Estado do Amazonas

Escola Superior de Tecnologia

Data: 26 de Setembro de 2018

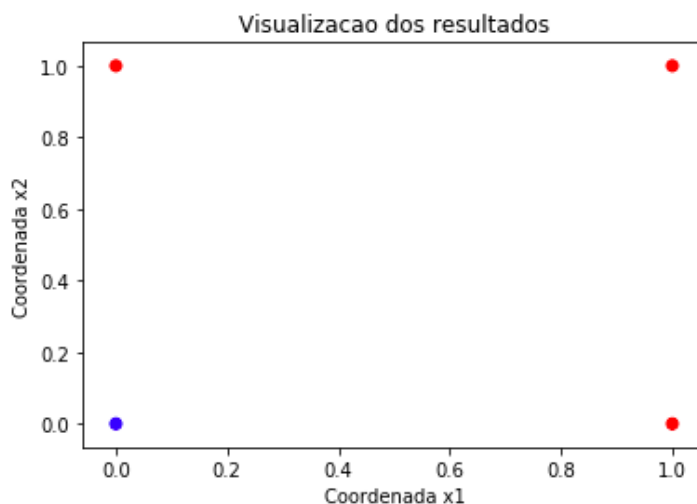
Professora: Elloá B. Guedes

Disciplina: Redes Neurais Artificiais

## ATIVIDADE PRÁTICA

Para consolidar esta atividade, os alunos devem se organizar em duplas balanceadas e produzir um **Jupyter notebook** para praticar o aprendizado de neurônios *perceptron*. Estes neurônios são conceitualmente simples e individualmente capazes de resolver problemas linearmente separáveis. O problema linearmente separável a ser considerado é o da porta lógica *NAND*, caracterizada pelas seguintes entradas e saídas:

$x_1$	$x_2$	$y$
0	0	1
0	1	0
1	0	0
1	1	0



A partir de uma inspeção visual é possível notar que este problema é linearmente separável. Nos resta, então, mostrar estes exemplos a um neurônio e deixar que o mesmo ajuste os pesos até o aprendizado da fronteira de decisão adequada.

## 1 Conjunto de Treinamento

Neste exemplo, o conjunto de treinamento é composto pelos atributos preditores  $x_1$  e  $x_2$  e atributo alvo  $y$ . No caso do neurônio *perceptron*, vamos acrescentar à entrada um *bias* igual a  $-1$ . De maneira breve, o *bias* atua auxiliando na formulação matemática, auxiliando a

determinar a fronteira de decisão para o problema em questão. Desta maneira, teremos o seguinte conjunto de treinamento.

```
# conjunto de treinamento com bias e conversao para numpy.array
X = [[-1,0,0],[-1,0,1],[-1,1,0],[-1,1,1]]
for i in range(len(X)):
    X[i] = np.asarray(X[i])

Y = [1,0,0,0]
```

## 2 Neurônio Perceptron

Neste problema, o neurônio *perceptron* deve possuir vetor  $W$  com 3 pesos inicializados aleatoriamente  $\sim U(-0.5, 0.5)$ . Os pesos atuarão sobre a entrada produzindo uma combinação linear, que passará pela função de ativação. A função de ativação a ser considerada será a função degrau com limiar igual a zero.

$$f(u = \sum_{i=1}^3 x_i \cdot w_i) = \begin{cases} 1, & u \geq 0. \\ 0, & c.c \end{cases} \quad (1)$$

O neurônio em questão deve examinar os exemplos de entrada e ajustar os pesos caso esteja produzindo uma solução diferente da desejada. Este processo é iterativo e continua até que, no caso de um problema linearmente separável, não haja mais erros de classificação. Este ajuste de pesos respeita à seguinte equação:

$$w(n+1) = w(n) + \eta \cdot (y_i - \hat{y}_i) \cdot x_i, \quad (2)$$

em que  $y_i$  é a saída correta para a entrada  $x_i$ ,  $\hat{y}_i$  é a saída produzida pelo neurônio para a entrada  $x_i$  e  $\eta$  é a taxa de aprendizado.

Assim, implemente o aprendizado de um neurônio perceptron para o conjunto de treinamento  $X$  e rótulos  $Y$  relativos à função *NAND*. Seu algoritmo deve ilustrar claramente:

1. O vetor de pesos a cada época;
2. A quantidade de exemplos corretos e errados a cada época;
3. A quantidade de épocas até a convergência;

4. A quantidade de vezes em que houve ajuste no vetor de pesos.


Para favorecer a prática dos conceitos relativos à biblioteca **numpy**, todo o processamento necessário deve, sempre que possível, ser implementado com funções de manipulação de matrizes disponíveis neste pacote.

### 3 Visualizando a Fronteira de Decisão

Após o processo de aprendizado, tem-se que o neurônio aprendeu os valores corretos do vetor de pesos capaz de separar adequadamente as classes deste exemplo. Para visualizar a fronteira de decisão a partir deste vetor de 3 pesos, construa uma reta da seguinte forma:

$$y = W[0]/W[2] - (W[1]/W[2]) * x, \quad (3)$$

em que os pesos identificados são utilizados para obter a forma canônica da reta característica da fronteira de decisão. Denote as classes em cores distintas, para facilitar a visualização dos resultados. O exemplo a seguir ilustra a construção desejada com resultados obtidos a partir do treinamento para aprendizado da função *OR*.



## 4 Funções de Ativação

Para complementar o entendimento para as próximas etapas da disciplina, apresente também gráficos para as seguintes funções de ativação, considerando o intervalo  $[-1.5, 1.5]$ :

1. Degrau (com  $\theta = 0.5$ );
2. Sigmoidal, com 3 valores distintos de suavidade e centro da curva no valor 0;
3. Tangente Hiperbólica;
4. ReLU.